embarca tech | Residência Tecnológica em Sistemas Embarcados

Aprendizagem de Máquina – Parte 4

RESIDÊNCIA – Aula Síncrona (13/01/2026)

Prof. Dr Ricardo Menezes Prates

Executores:
INSTITUTO FEDERAL Piauí
INSTITUTO FEDERAL Rio Grande do Norte
INSTITUTO FEDERAL Maranhão
INSTITUTO FEDERAL Ceará
cepedi
INSTITUTO HARDWARE BR
Coordenação: Softex
Iniciativa: MINISTÉRIO DA CIÊNCIA, TECNOLOGIA E INOVAÇÃO
GOVERNO FEDERAL BRASIL UNIÃO E RECONSTRUÇÃO

- *Introdução*
  - Planejamento da aula

- Aprendizagem de Máquina para Sistemas Embarcados
  - *Rede Neural Convolucional (CNN) para TinyML*
  - *Rede Neural Recorrente (RNN) para denoising supervisionado.*

- Conclusões

Introdução

Objetivo 1

- Implementar uma Rede Neural Convolucional (CNN), embarcada no Raspberry Pi Pico W.

- Utilizar o google colab e a biblioteca TensorFlow Lite Micro (TFLM) para executar inferência de imagens (dataset MNIST) diretamente no microcontrolador.

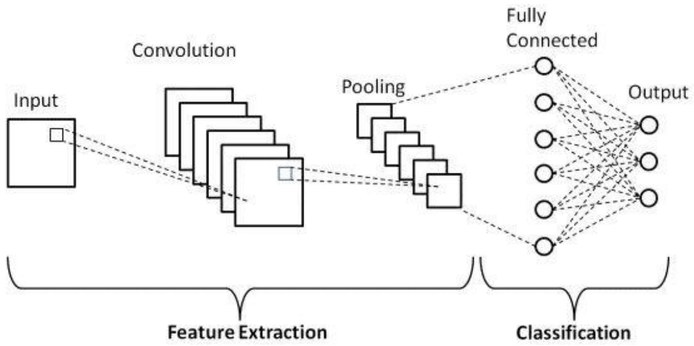

Rede Neural Convolucional (CNN)

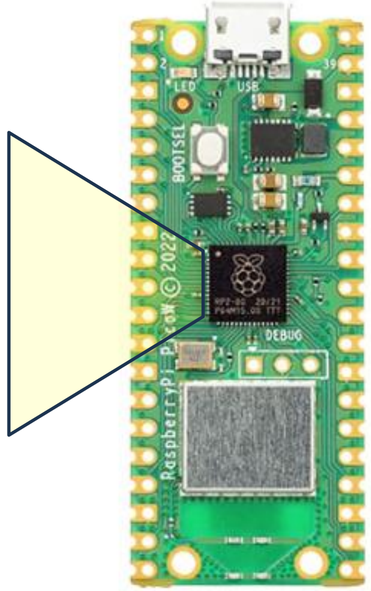

Objetivo 2

- Implementar uma Rede Neural Recorrente (RNN), no google colab direcionada a tarefa de *denoising* supervisionado .

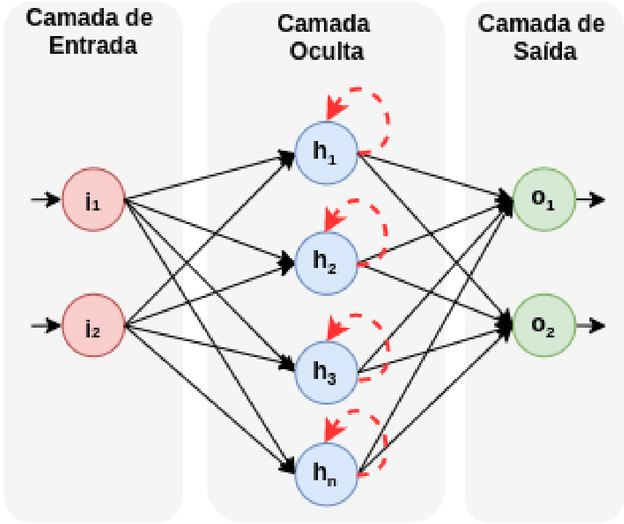

Rede Neural Recorrente (RNN)

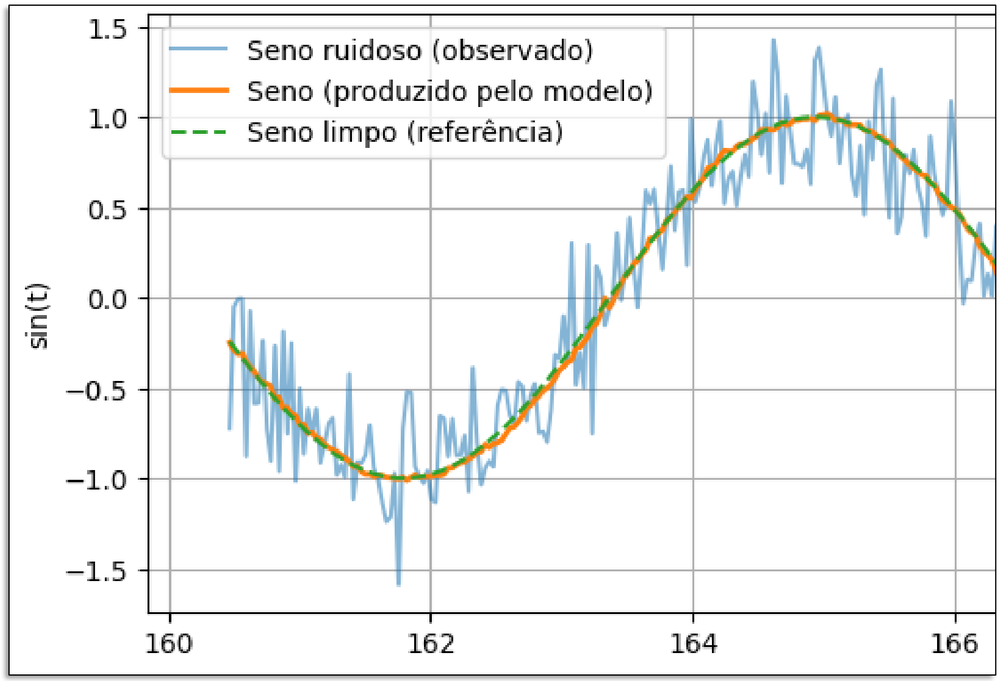

Denoising supervisionado

Planejamento da Aula

- Potenciais perguntas a serem trabalhadas nesta aula.

✓ É possível implementar modelos de aprendizagem profunda no Raspberry Pi Pico W para fazer inferências?

✓ Quais as principais características das CNNs e Redes Neurais Recorrentes (RNNs)?

✓ Como posso trabalhar com regressão supervisionada em aprendizagem de máquina?

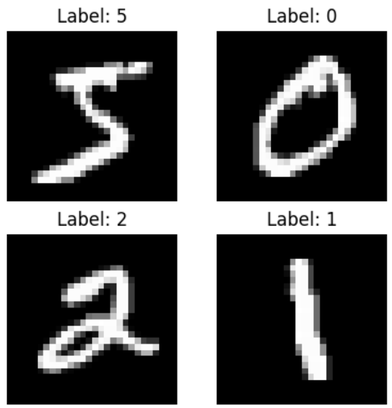

Dataset MNIST

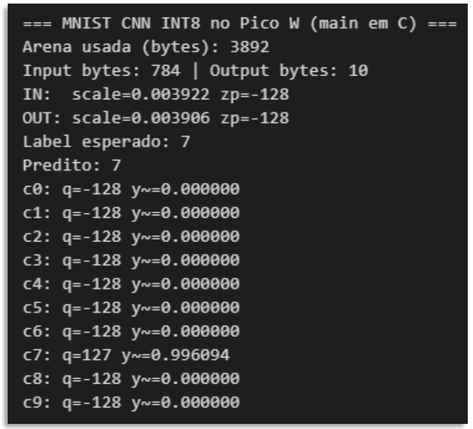

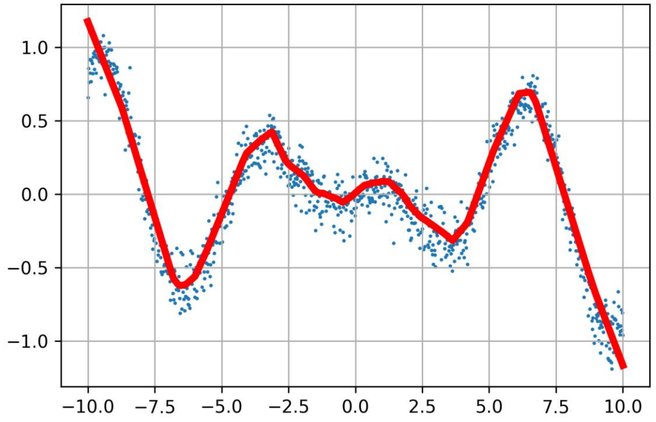

Aprendizagem de Máquina - Revisão

- O que é?

✓ Principais tipos de aprendizado de máquina:

Aprendizado supervisionado: o modelo aprende a partir de dados rotulados (com respostas conhecidas).

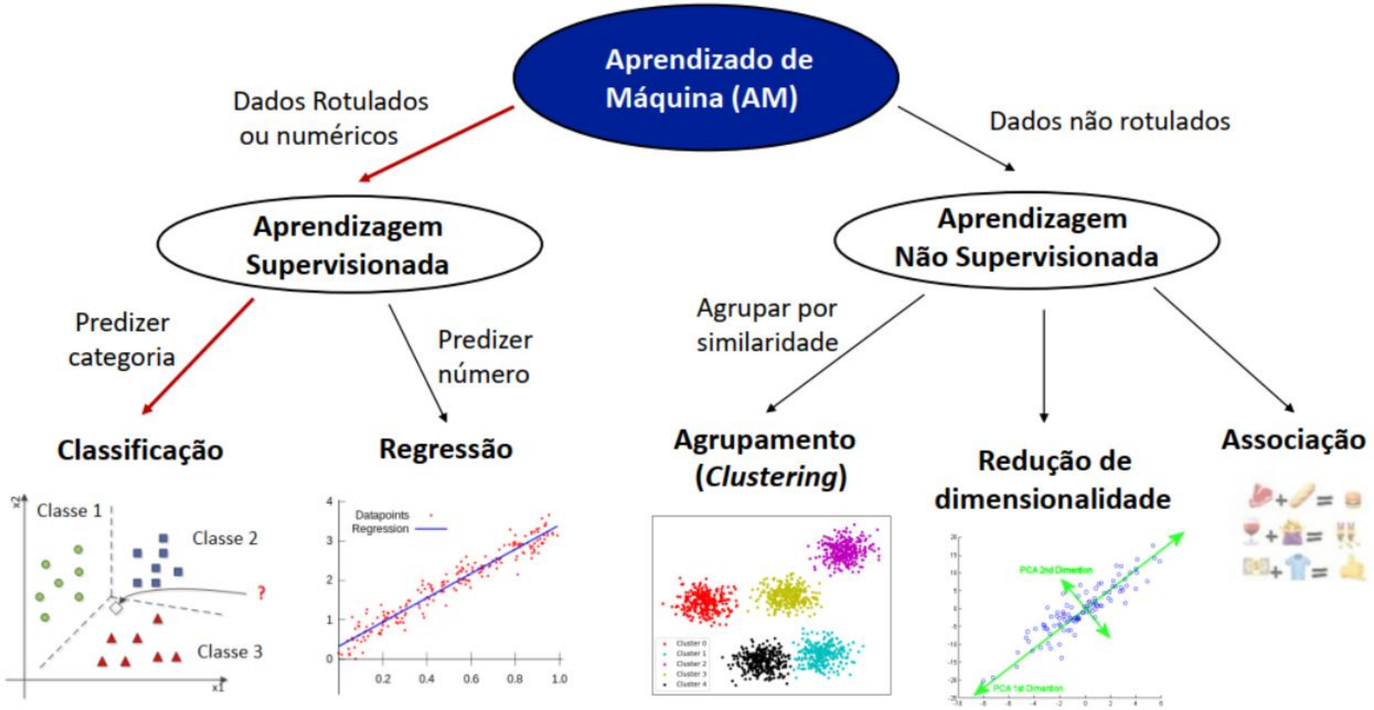

Ex. 1 Ex. 2

Sistemas embarcados - Revisão

- TinyML– Fluxo de trabalho para o RP2040

1. Treinar o modelo em Tensorflow;
2. Converter para TFLite;
3. Quantizar – opcional, recomendado para o TinyML;
4. Exportar como array C;
5. Compilar junto ao *firmware – bare metal*;
6. Executar inferências no microcontrolador.

```
unsigned char iris_mlp_float_tflite[] = {
  0x1c, 0x00, 0x00, 0x00, 0x54, 0x46, 0x4c, 0x33, 0x14, 0x00, 0x20, 0x00,
  0x1c, 0x00, 0x18, 0x00, 0x14, 0x00, 0x10, 0x00, 0x0c, 0x00, 0x00, 0x00,
  0x08, 0x00, 0x04, 0x00, 0x14, 0x00, 0x00, 0x00, 0x1c, 0x00, 0x00, 0x00,
  0x98, 0x00, 0x00, 0x00, 0xf0, 0x00, 0x00, 0x00, 0xdc, 0x05, 0x00, 0x00,
  0xec, 0x05, 0x00, 0x00, 0x8c, 0x0b, 0x00, 0x00, 0x03, 0x00, 0x00, 0x00,
  0x01, 0x00, 0x00, 0x00, 0x10, 0x00, 0x00, 0x00, 0x00, 0x00, 0x0a, 0x00,
  0x10, 0x00, 0x0c, 0x00, 0x08, 0x00, 0x04, 0x00, 0x0a, 0x00, 0x00, 0x00,
  0x0c, 0x00, 0x00, 0x00, 0x1c, 0x00, 0x00, 0x00, 0x3c, 0x00, 0x00, 0x00,
  0x0f, 0x00, 0x00, 0x00, 0x73, 0x65, 0x72, 0x76, 0x69, 0x6e, 0x67, 0x5f,
  0x64, 0x65, 0x66, 0x61, 0x75, 0x6c, 0x74, 0x00, 0x01, 0x00, 0x00, 0x00,
  0x04, 0x00, 0x00, 0x00, 0x90, 0xff, 0xff, 0xff, 0x0a, 0x00, 0x00, 0x00,
  0x04, 0x00, 0x00, 0x00, 0x08, 0x00, 0x00, 0x00, 0x6f, 0x75, 0x74, 0x70,
  0x75, 0x74, 0x5f, 0x30, 0x00, 0x00, 0x00, 0x00, 0x01, 0x00, 0x00, 0x00,
  0x04, 0x00, 0x00, 0x00, 0x0a, 0xfa, 0xff, 0xff, 0x04, 0x00, 0x00, 0x00,
  0x0c, 0x00, 0x00, 0x00, 0x6b, 0x65, 0x72, 0x61, 0x73, 0x5f, 0x74, 0x65,
  0x6e, 0x73, 0x6f, 0x72, 0x00, 0x00, 0x00, 0x00, 0x02, 0x00, 0x00, 0x00,
  0x34, 0x00, 0x00, 0x00, 0x04, 0x00, 0x00, 0x00, 0xdc, 0xff, 0xff, 0xff,
  0x0d, 0x00, 0x00, 0x00, 0x04, 0x00, 0x00, 0x00, 0x13, 0x00, 0x00, 0x00,
  0x43, 0x4f, 0x4e, 0x56, 0x45, 0x52, 0x53, 0x49, 0x4f, 0x4e, 0x5f, 0x4d,
```

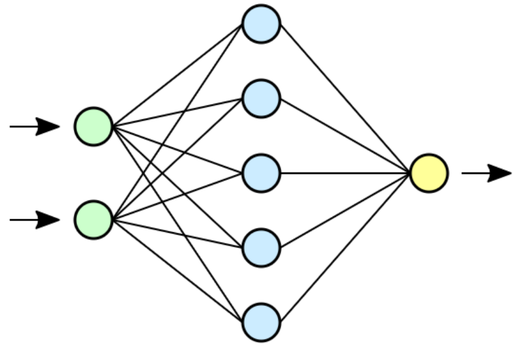

Sistemas embarcados - Revisão

- TensorFlow Lite Micro – pico-tflmicro

✓ Implementação otimizada da biblioteca TensorFlow Lite Micro, desenvolvida especificamente para o microcontrolador RP2040 (Raspberry Pi Pico / Pico W);

✓ Fornece uma forma simplificada, eficiente e estável de rodar modelos TinyML no Pico usando o Pico SDK.

Redes Neurais Convolucionais (CNN)

- Definição:

✓ Para Haykin, uma CNN pode ser definida como uma classe especial de RNA Perceptron de Múltiplas Camadas (*Multilayer Perceptron* - MLP), que foi concebida especialmente para reconhecer padrões em datasets bidimensionais.

✓ Já para Goodfellow et al., estes algoritmos podem ser entendidos simplesmente como redes neurais que utilizam a operação de convolução ao invés de multiplicação geral entre matrizes em pelo menos um dos seus estágios de processamento.

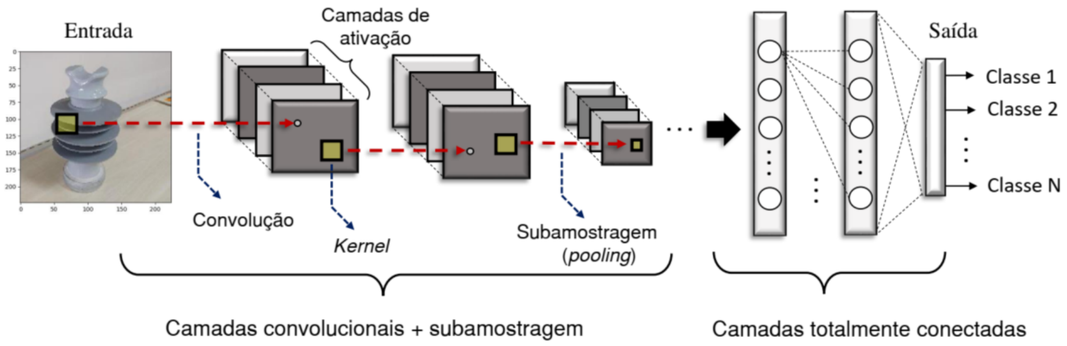

Redes Neurais Convolucionais (CNN)

- Visão computacional:

✓ De acordo com CLeCun e Bengio, as RNCs apresentam, como características de mérito, a exemplo do alto grau de invariância em relação:

a. Translação,

b. Alteração de escala,

c. Inclinação e outras formas de distorção, tornando-se, por exemplo, uma importante ferramenta para tarefas de processamento de imagens.

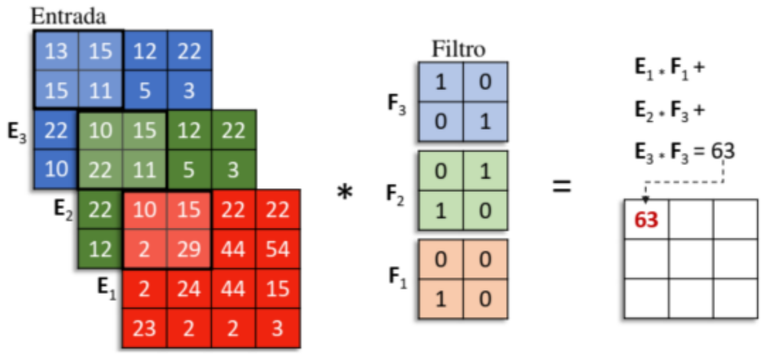

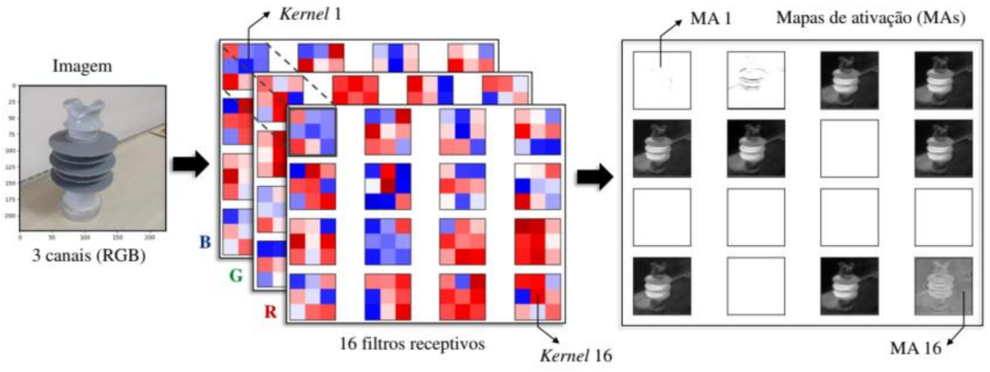

Redes Neurais Convolucionais (CNN)

- Emprego em TinyML – otimização:

1) Reduza o número de ativações/pesos (menor demanda de RAM): menor resolução de entrada; menos filtros receptivos nas primeiras camadas; prefira o *stride* 2 em vez de *pooling* (maior custo computacional) e evite arquiteturas com muitos ramos.

2) Use operadores suportados pelo microcontrolador (TFLM): Conv2D 3×3 e 1×1, ReLU; GlobalAveragePooling no final em vez de camadas densas enormes, Camadas densas pequenas só no final.

3) Quantização (quase sempre INT8); *pruning* estruturado (remover filtros/canais inteiros) e :Knowledge distillation - treine um "professor" maior e destile para um "aluno" menor.

4) Ajustes de compilação e runtime (TFLM).

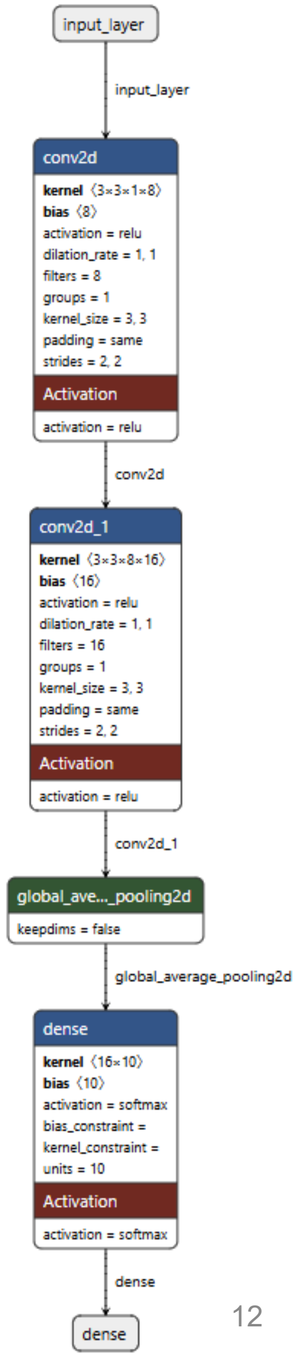

Redes Neurais Recorrentes (RNN)

- Definição:

✓ As Redes Neurais Recorrentes (*RNN – Recurrent Neural Networks*) são modelos de Aprendizado de Máquina projetados para lidar com dados *sequenciais e temporais*, nos quais a ordem e o contexto das informações são fundamentais.

✓ Diferentemente das redes neurais tradicionais (*feedforward*), as RNNs possuem realimentação interna, permitem que informações de estados anteriores influenciem as saídas futuras.

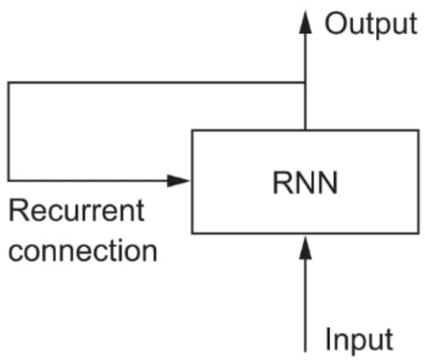

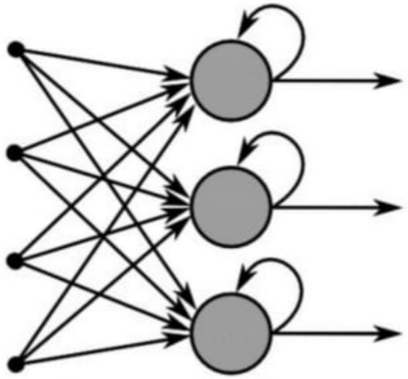

Redes Neurais Recorrentes (RNN)

- Definição:

✓ Uma RNN processa uma sequência passo a passo no tempo, mantendo um estado interno (memória) que representa informações acumuladas até aquele instante.

✓ Exemplos de RNNs:

I) Simple RNN (RNN de Elman ou RNN padrão) – forma básica;

II) LSTM (*Long Short-Term Memory*)

III) GRU (*Gated Recurrent Unit*)

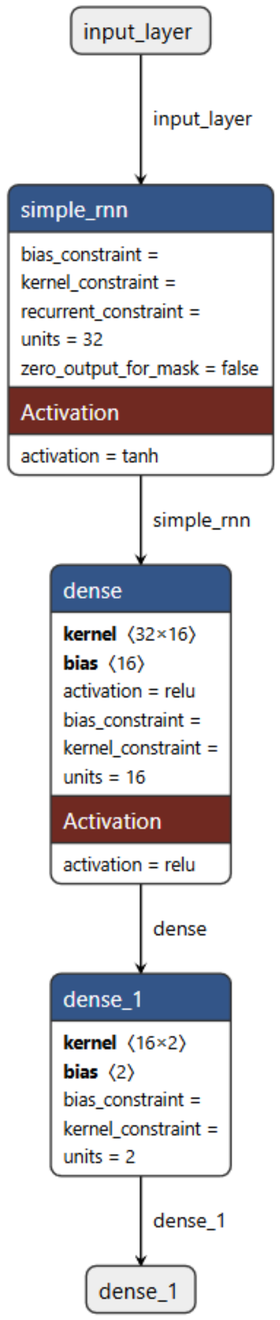

Redes Neurais Recorrentes (RNN)

- Características principais:

✓ Memória temporal: a rede "lembra" eventos anteriores.

✓ Pesos compartilhados no tempo: o mesmo conjunto de pesos é usado em todos os instantes.

✓ *Processamento sequencial*: adequado para séries temporais e sinais.

✓ Capacidade de modelar dependências temporais.

✓ Problemas Clássicos: *Vanishing Gradient* (tendem a zero) e *Exploding Gradient* (crescem excessivamente).

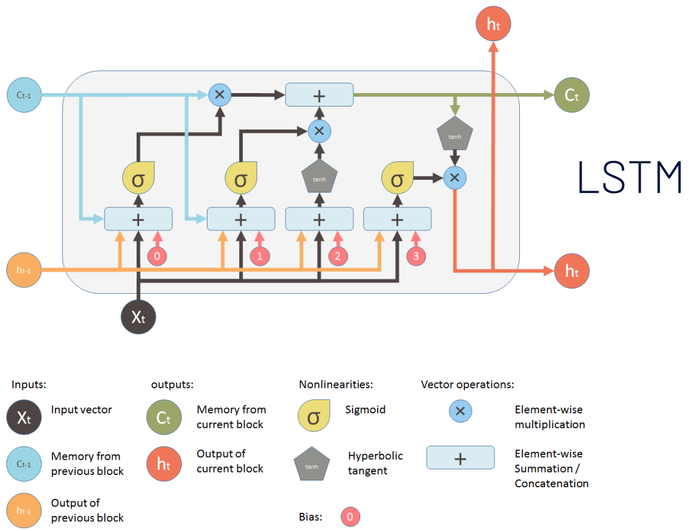

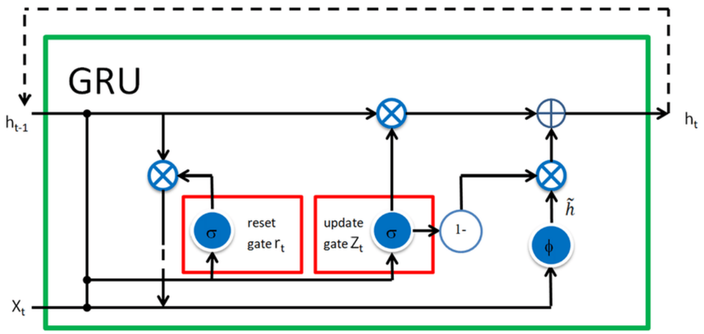

Redes Neurais Recorrentes (RNN)

- Exemplos de aplicação:

📈 Previsão de séries temporais (dados de sensores, energia, clima, mercado financeiro).

🗣️ Processamento de linguagem natural (NLP).

📢 Reconhecimento de fala e áudio.

🤖 Controle e navegação de robôs.

📡 Análise de sinais e IoT temporal.

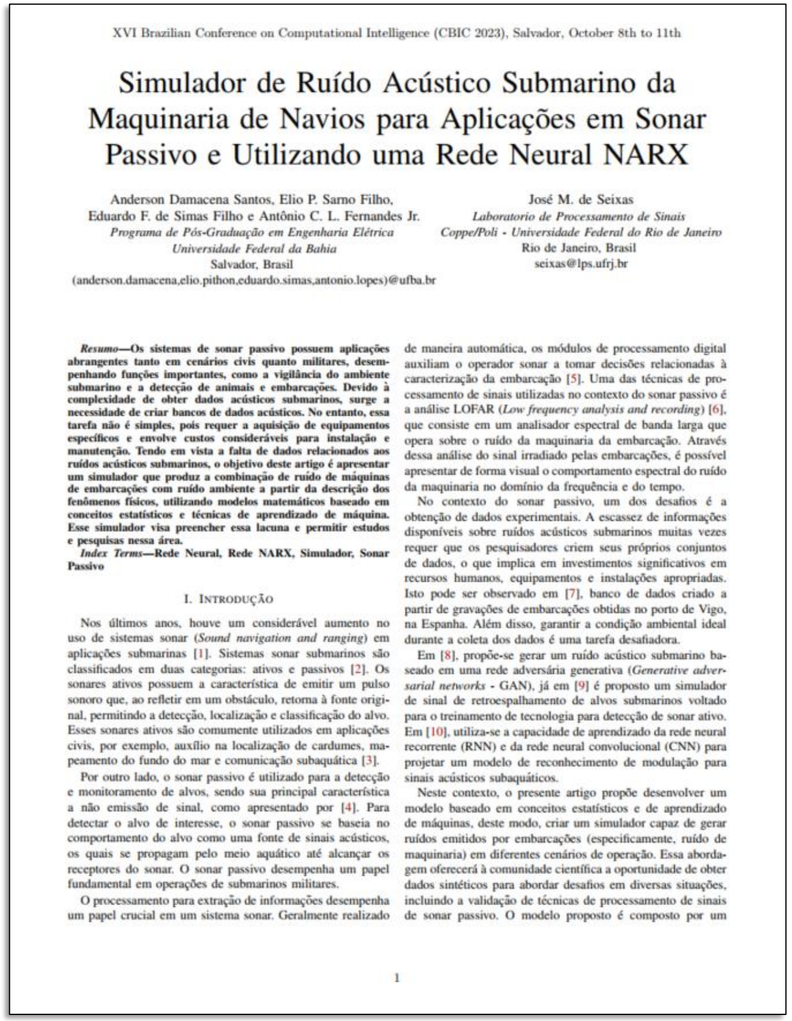

XVI Brazilian Conference on Computational Intelligence (CBIC 2023), Salvador, October 8th to 11th

Simulador de Ruído Acústico Submarino da Maquinaria de Navios para Aplicações em Sonar Passivo e Utilizando uma Rede Neural NARX

Anderson Damacena Santos, Elio P. Sarno Filho,
Eduardo F. de Simas Filho e Antônio C. L. Fernandes Jr.
Programa de Pós-Graduação em Engenharia Elétrica
Universidade Federal da Bahia
Salvador, Brasil
(anderson.damacena,elio.pithon,eduardo.simas,antonio.lopes)@ufba.br

José M. de Seixas
Laboratorio de Processamento de Sinais
Coppe/Poli - Universidade Federal do Rio de Janeiro
Rio de Janeiro, Brasil
seixas@lps.ufrj.br

***Resumo*—Os sistemas de sonar passivo possuem aplicações abrangentes tanto em cenários civis quanto militares, desempenhando funções importantes, como a vigilância do ambiente submarino e a detecção de animais e embarcações. Devido à complexidade de obter dados acústicos submarinos, surge a necessidade de criar bancos de dados acústicos. No entanto, essa tarefa não é simples, pois requer a aquisição de equipamentos específicos e envolve custos consideráveis para instalação e manutenção. Tendo em vista a falta de dados relacionados aos ruídos acústicos submarinos, o objetivo deste artigo é apresentar um simulador que produz a combinação de ruído de máquinas de embarcações com ruído ambiente a partir da descrição dos fenômenos físicos, utilizando modelos matemáticos baseado em conceitos estatísticos e técnicas de aprendizado de máquina. Esse simulador visa preencher essa lacuna e permitir estudos e pesquisas nessa área.**

***Index Terms*—Rede Neural, Rede NARX, Simulador, Sonar Passivo**

I. Introdução

Nos últimos anos, houve um considerável aumento no uso de sistemas sonar (*Sound navigation and ranging*) em aplicações submarinas [1]. Sistemas sonar submarinos são classificados em duas categorias: ativos e passivos [2]. Os sonares ativos possuem a característica de emitir um pulso sonoro que, ao refletir em um obstáculo, retorna à fonte original, permitindo a detecção, localização e classificação do alvo. Esses sonares ativos são comumente utilizados em aplicações civis, por exemplo, auxílio na localização de cardumes, mapeamento do fundo do mar e comunicação subaquática [3].

Por outro lado, o sonar passivo é utilizado para a detecção e monitoramento de alvos, sendo sua principal característica a não emissão de sinal, como apresentado por [4]. Para detectar o alvo de interesse, o sonar passivo se baseia no comportamento do alvo como uma fonte de sinais acústicos, os quais se propagam pelo meio aquático até alcançar os receptores do sonar. O sonar passivo desempenha um papel fundamental em operações de submarinos militares.

O processamento para extração de informações desempenha um papel crucial em um sistema sonar. Geralmente realizado de maneira automática, os módulos de processamento digital auxiliam o operador sonar a tomar decisões relacionadas à caracterização da embarcação [5]. Uma das técnicas de processamento de sinais utilizadas no contexto do sonar passivo é a análise LOFAR (*Low frequency analysis and recording*) [6], que consiste em um analisador espectral de banda larga que opera sobre o ruído da maquinaria da embarcação. Através dessa análise do sinal irradiado pelas embarcações, é possível apresentar de forma visual o comportamento espectral do ruído da maquinaria no domínio da frequência e do tempo.

No contexto do sonar passivo, um dos desafios é a obtenção de dados experimentais. A escassez de informações disponíveis sobre ruídos acústicos submarinos muitas vezes requer que os pesquisadores criem seus próprios conjuntos de dados, o que implica em investimentos significativos em recursos humanos, equipamentos e instalações apropriadas. Isto pode ser observado em [7], banco de dados criado a partir de gravações de embarcações obtidas no porto de Vigo, na Espanha. Além disso, garantir a condição ambiental ideal durante a coleta dos dados é uma tarefa desafiadora.

Em [8], propõe-se gerar um ruído acústico submarino baseado em uma rede adversária generativa (*Generative adversarial networks* - GAN), já em [9] é proposto um simulador de sinal de retroespalhamento de alvos submarinos voltado para o treinamento de tecnologia para detecção de sonar ativo. Em [10], utiliza-se a capacidade de aprendizado da rede neural recorrente (RNN) e da rede neural convolucional (CNN) para projetar um modelo de reconhecimento de modulação para sinais acústicos subaquáticos.

Neste contexto, o presente artigo propõe desenvolver um modelo baseado em conceitos estatísticos e de aprendizado de máquinas, deste modo, criar um simulador capaz de gerar ruídos emitidos por embarcações (especificamente, ruído de maquinaria) em diferentes cenários de operação. Essa abordagem oferecerá à comunidade científica a oportunidade de obter dados sintéticos para abordar desafios em diversas situações, incluindo a validação de técnicas de processamento de sinais de sonar passivo. O modelo proposto é composto por um

1

Redes Neurais Recorrentes (RNN)

✅ Vantagens

- Capturam dependências temporais.
- Modelam sequências de tamanho variável.
- Fundamentais em problemas dinâmicos.

❌ Limitações

- Treinamento mais lento.
- Dificuldade com sequências longas (RNN simples).

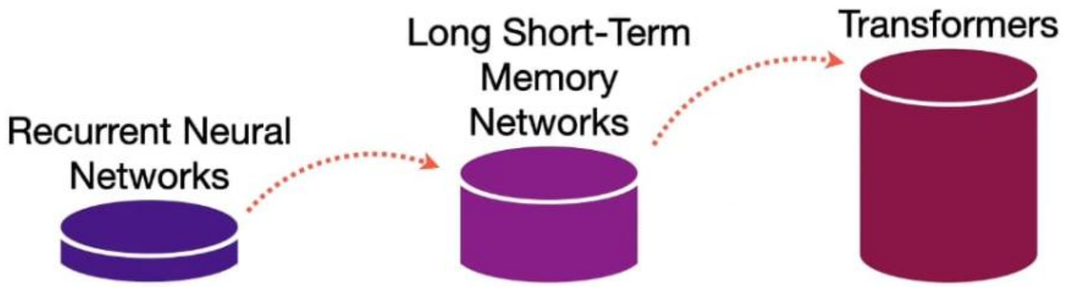

Nota: Hoje, em muitos casos, substituídas por Transformers, mas ainda muito relevantes em sistemas embarcados e séries temporais curtas.

Exemplos de aplicação

Vamos para o código!

Exemplo 1

Rede Neural Convolucional (CNN)

Objetivo: Desenvolver Rede Neural Convolucional (CNN) para classificação de imagens de entrada com o TensorFlow e TensorFlow Lite Micro (TFLM).

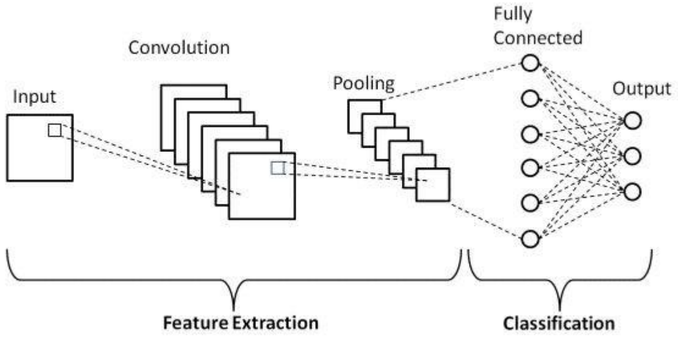

Rede Neural Convolucional (CNN)

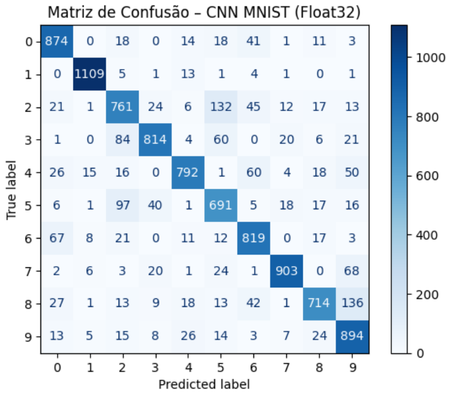


```
...  #include <cstdint>


     alignas(16) const unsigned char mnist_cnn_int8_model[] = {

       0x1c, 0x00, 0x00, 0x00, 0x54, 0x46, 0x4c, 0x33, 0x14, 0x00, 0x20, 0x00,

       0x1c, 0x00, 0x18, 0x00, 0x14, 0x00, 0x10, 0x00, 0x0c, 0x00, 0x00, 0x00,

       0x08, 0x00, 0x04, 0x00, 0x14, 0x00, 0x00, 0x00, 0x1c, 0x00, 0x00, 0x00,

       0x98, 0x00, 0x00, 0x00, 0x18, 0x01, 0x00, 0x00, 0x68, 0x08, 0x00, 0x00,

       0x78, 0x08, 0x00, 0x00, 0xf4, 0x13, 0x00, 0x00, 0x03, 0x00, 0x00, 0x00,

       0x01, 0x00, 0x00, 0x00, 0x10, 0x00, 0x00, 0x00, 0x00, 0x00, 0x0a, 0x00,

       0x10, 0x00, 0x0c, 0x00, 0x08, 0x00, 0x04, 0x00, 0x0a, 0x00, 0x00, 0x00,

       0x0c, 0x00, 0x00, 0x00, 0x1c, 0x00, 0x00, 0x00, 0x3c, 0x00, 0x00, 0x00,
```

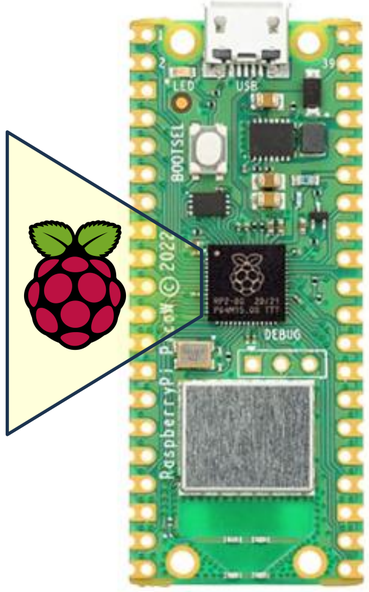

GitHub

Vamos para o código!

Exemplo 2

colab

TensorFlow

Modelo Inteligente Embarcado

Objetivo: Desenvolver Rede Neural Recorrente (RNN) direcionada a tarefa de denoising supervisionado.

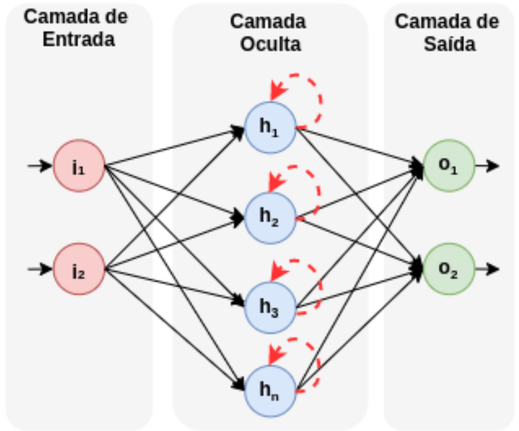

Rede Neural Recorrente (RNN)

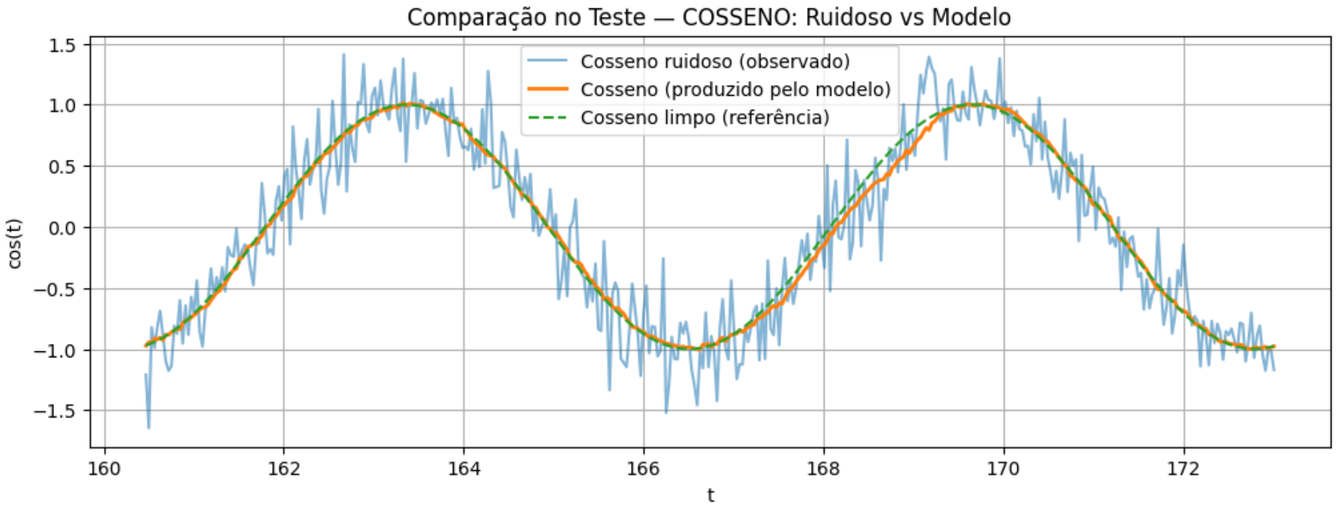

Conclusões

Conclusões

- Modelos de aprendizagem profunda, a exemplo de Redes Neurais Convolucionais (CNNs), também podem ser adaptados para demandas de TinyML no RP2040.

- Em sistemas embarcados, RNNs compactas —SimpleRNN e NARX — permitem implementar sistemas de denoising inteligente baseado em dados, aprendendo diretamente a estrutura temporal do processo monitorado.

- Os modelos inteligente embarcados permitem que microcontroladores e SBCs deixem de ser apenas leitores de sensores e passem a ser dispositivos de percepção, capazes de interpretar o mundo em tempo real.

Bibliografia Recomendada

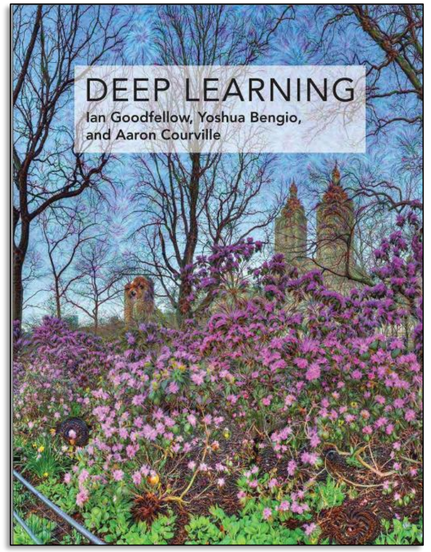

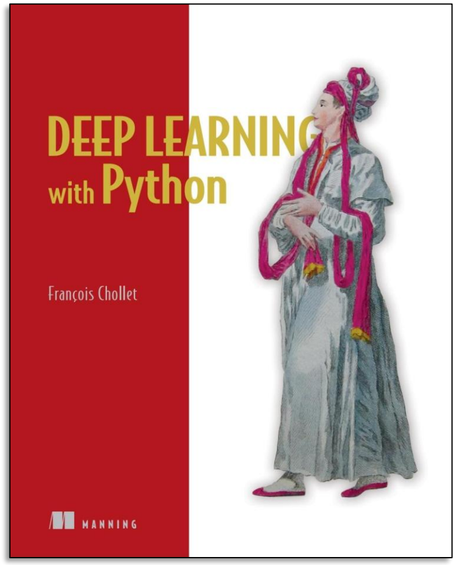

Repositório de artigos sobre TinyML:
https://www.dropbox.com/scl/fo/8j88u23pryfaewn1ishjl/AI49QdtNTRw2nIDqbR0gBcE?rlkey=8k0s74u2a9yjsvkl470y2f0zr&dl=0

embarca tech | Residência Tecnológica em Sistemas Embarcados

Aprendizagem de Máquina – Parte 4

RESIDÊNCIA – Aula Síncrona (13/01/2026)

Prof. Dr Ricardo Menezes Prates

Executores:
INSTITUTO FEDERAL Piauí
INSTITUTO FEDERAL Rio Grande do Norte
INSTITUTO FEDERAL Maranhão
INSTITUTO FEDERAL Ceará
cepedi
INSTITUTO HARDWARE BR
Coordenação: Softex
Iniciativa: MINISTÉRIO DA CIÊNCIA, TECNOLOGIA E INOVAÇÃO
GOVERNO FEDERAL BRASIL UNIÃO E RECONSTRUÇÃO